
Classification d'images par reseaux de neurones convolutifs (CNN)

Jeu de donnees CIFAR-10 : architectures VGG, optimiseurs, learning rate et regularisation

Mehdi Redha BELLAHSENE

Methodologie CRISP-DM . Python / TensorFlow / Keras . Juin 2026

Resume

Ce travail etudie la classification d'images CIFAR-10 par CNN. Nous comparons une architecture de base (LeNet-5) a des VGG (1 a 3 blocs), evaluons l'effet de l'optimiseur (SGD, Adam) et du learning rate, puis l'apport de la regularisation (Dropout, Batch Normalization), selon CRISP-DM. La meilleure configuration imposee (VGG3+D+BN, Adam, LR=0.001) atteint 82.8 %. En allant plus loin, le transfer learning (EfficientNetB5_TL) porte la precision a 97.9 %, le meilleur resultat du projet.

1. Introduction et methodologie

L'objectif de ce projet est d'implementer des reseaux de neurones convolutifs (CNN) pour la classification d'images du jeu CIFAR-10 : etude des architectures de type VGG, comparaison des optimiseurs SGD et Adam sur trois learning rates, et evaluation des techniques de regularisation (Dropout, Batch Normalization).

1.1 Methodologie CRISP-DM (les six phases)

La demarche suit la methodologie CRISP-DM (Cross-Industry Standard Process for Data Mining), un processus iteratif en six phases ; voici comment chacune se concretise dans ce projet :

- Compréhension du probleme : classer des images couleur 32x32 en 10 categories mutuellement exclusives (tache de vision par ordinateur).
- Compréhension des donnees : exploration de CIFAR-10 -- dimensions, exemples visuels, distribution des classes (section 2).
- Preparation des donnees : normalisation des pixels dans [0,1] et encodage one-hot des labels (section 2).
- Modelisation : construction de LeNet-5, VGG1/2/3 et des variantes regularisees ; choix des optimiseurs et des learning rates (section 3).
- Evaluation : tableau de performances, courbes d'apprentissage et analyse comparative des resultats (section 4).
- Deploiement : selection du modele retenu (section 5) et extensions pour la precision maximale (sections 6-7) ; un jeu interactif illustre l'usage du modele.

1.2 Environnement d'execution et consommation des ressources

Les entrainements ont ete realises en Python (TensorFlow / Keras) sur Google Colab, avec un GPU NVIDIA A100 (80 Go de memoire GPU) dans un environnement a HAUTE MEMOIRE (High-RAM, 167 Go de RAM systeme). Cette configuration High-RAM a ete necessaire pour entrainer le modele de transfer learning EfficientNetB5 a haute resolution (456x456) sans saturation de la memoire. Le transfer learning emploie en outre la precision mixte (float16) pour exploiter les Tensor Cores du GPU et acclereler l'entrainement.

Point sur l'execution. La grille des 36 configurations (modeles legers) s'entraine en quelques minutes ; a l'inverse, EfficientNetB5 -- le plus gros modele -- sollicite fortement le GPU (environ 18 minutes par epoque en fine-tuning a 456x456). La capture ci-dessous montre la consommation des ressources (RAM systeme, memoire GPU, disque) pendant l'execution sur l'environnement A100 High-RAM.




Figure. Consommation des ressources sur Colab (A100, environnement High-RAM).

2. Compréhension et préparation des données

2.1 Jeu de données (Tache 1)

CIFAR-10 : images couleur 32x32 (3 canaux RVB), 10 classes mutuellement exclusives.

Caractéristique	Valeur
Images d'entraînement	50 000
Images de test	10 000
Dimensions image	32 x 32 x 3
Canaux	3
Classes	10

Table 1. Caractéristiques de CIFAR-10.

50 000 images d'entraînement et 10 000 de test. La faible résolution rend la tâche difficile (classes proches : chat/chien, automobile/camion).

2.2 Visualisation (Tache 2)

Les labels sont des données CATEGORIELLES (et non numériques ordonnées) : chaque entier de 0 à 9 désigne une catégorie (avion, automobile, ...), sans relation d'ordre entre elles. Visuellement, la très faible résolution (32x32) rend certaines images difficiles à classer, y compris pour un humain -- notamment des classes proches comme chat / chien ou automobile / camion.




Figure 1. Echantillon d'images CIFAR-10 et leurs classes.

2.3 Normalisation (Tache 3)

Les pixels (0-255) sont ramenés dans $[0,1]$ par division par 255. Cela place les entrées sur une échelle commune, stabilise et accélère la descente de gradient.

2.4 Encodage one-hot (Tache 4)

Les labels deviennent des vecteurs one-hot (classe 3 $\rightarrow [0,0,0,1,0,0,0,0,0]$). Cela évite toute relation d'ordre entre classes et s'accorde avec softmax + entropie croisée.

2.5 Distribution des classes (Tache 5)

CIFAR-10 est équilibré : 5 000 images par classe. Un déséquilibre biaiserait le modèle.




Figure 2. Distribution des classes (5 000 chacune).

3. Modelisation : architectures, optimiseurs, regularisation

3.1 Architectures

Les architectures de type VGG (Simonyan & Zisserman, 2014) empilent des blocs convolutifs identiques. Un bloc VGG = Conv -> Conv -> MaxPool (32 filtres 3x3, pooling 2x2) ; suit une couche cachee Dense(128) puis la sortie softmax(10). Six modeles :

- CNN1 : reseau de base (LeNet-5), reference.
- VGG1/2/3 : 1, 2 ou 3 blocs (profondeur croissante).
- VGG3+Drop : VGG3 + Dropout.
- VGG3+Drop+BatchNorm : VGG3 + Dropout + Batch Normalization.

Modele	Blocs VGG	Parametres
CNN1	-	136 886
VGG1	1	1 060 138
VGG2	2	292 202
VGG3	3	114 090
VGG3+D	3	114 090
VGG3+D+BN	3	115 370

Table 2. Nombre de parametres par architecture.

3.2 Optimiseurs (SGD et Adam)

Un optimiseur est l'algorithme qui ajuste les poids du reseau afin de minimiser la fonction de perte. A chaque iteration, il exploite les gradients calcules par retropropagation pour mettre a jour chaque poids dans la direction qui reduit l'erreur. Son role est central : il determine la vitesse, la stabilite et la qualite finale de l'apprentissage.

- SGD (descente de gradient stochastique) met a jour chaque poids d'un pas fixe : $w \leftarrow w - lr \times \text{gradient}$. Simple et robuste, mais sensible au choix du learning rate et plus lent ; le momentum (0,9) accumule les gradients passes pour accelerer et lisser la trajectoire.
- Adam (Adaptive Moment Estimation) combine le momentum (moyenne des gradients) et un learning rate adaptatif par parametre (via la moyenne des carres des gradients) : $w \leftarrow w - lr \times m / (\text{racine}(v) + \text{eps})$. Il converge plus vite et demande moins de reglage, d'ou son statut de choix par defaut pour les CNN.

Quel optimiseur pour l'architecture VGG ? L'analyse (section 4.3) le montre : Adam est le plus performant a faible learning rate (0.001), mais il diverge a learning rate eleve, ou SGD reste plus robuste. (Refs : Kingma & Ba, 2015 ; Analytics Vidhya, 2021.)

3.3 Regularisation : Dropout et Batch Normalization (Bonus)

Dropout. Pendant l'entrainement, le Dropout desactive aleatoirement une fraction des neurones (20 a 50 % ici) a chaque etape : le reseau ne peut plus dependre de neurones specifiques et apprend des representations redondantes et robustes, ce qui reduit le surapprentissage. Difference essentielle entre les deux phases : le Dropout n'agit qu'a l'ENTRAINEMENT ; en INFERENCE, tous les neurones sont conserves et leurs sorties mises a l'echelle de maniere coherente. (Ref : Srivastava et al., 2014.)

Batch Normalization. Elle normalise les activations de chaque couche au sein d'un mini-batch (moyenne nulle, variance unitaire), puis les remet a l'echelle via deux parametres appris. Objectifs et benefices : reduire le decalage de distribution interne (covariate shift), ce qui stabilise et accelere l'entrainement, autorise des

learning rates plus eleves et exerce un leger effet regularisant. (Ref : Ioffe & Szegedy, 2015.)

3.4 Protocole

Entropie croisee categorielle, batch 64, max 50 epoques, early stopping. Trois learning rates (0.001, 0.01, 0.1) x deux optimiseurs ; LR fixe pendant chaque entrainement. Le test sert de validation.

4. Implementation et evaluation des performances

4.1 Tableau des performances (precision de test)

Precision test (%)	LR = 0.001		LR = 0.01		LR = 0.1	
	<i>SGD</i>	<i>Adam</i>	<i>SGD</i>	<i>Adam</i>	<i>SGD</i>	<i>Adam</i>
CNN1	64.3	64.1	63.9	53.1	10.0	10.0
VGG1	66.6	68.6	68.3	45.0	44.2	10.0
VGG2	67.7	74.3	70.8	54.0	10.0	10.0
VGG3	71.7	75.5	73.1	10.0	10.0	10.0
VGG3+D	71.4	78.6	76.0	10.0	10.0	10.0
VGG3+D+BN	78.2	82.8	82.8	81.3	81.8	59.6

Table 3. Precision de test (%). CNN1 = LeNet-5 ; VGG3+D = VGG3 + Dropout ; VGG3+D+BN = VGG3 + Dropout + Batch Normalization.

Meilleure configuration : VGG3+D+BN / Adam / LR=0.001 -> 82.82 % (entrainement 89.03 %).

4.2 Perte de test

Perte test	LR = 0.001		LR = 0.01		LR = 0.1	
	<i>SGD</i>	<i>Adam</i>	<i>SGD</i>	<i>Adam</i>	<i>SGD</i>	<i>Adam</i>
CNN1	1.14	1.06	1.10	1.40	2.31	2.31
VGG1	1.25	0.91	0.96	1.55	1.77	2.31
VGG2	1.01	0.90	1.00	1.30	2.30	2.31
VGG3	0.93	0.79	0.82	2.30	2.31	2.31
VGG3+D	0.80	0.62	0.71	2.30	2.31	2.31
VGG3+D+BN	0.63	0.51	0.51	0.55	0.56	1.18

Table 4. Perte (entropie croisee). CNN1 = LeNet-5 ; VGG3+D = VGG3 + Dropout ; VGG3+D+BN = VGG3 + Dropout + Batch Normalization.




Figure 3. Précision de test (heatmap) : modèles x (learning rate, optimiseur).




Figure 4. Précision de test par architecture et optimiseur (au meilleur learning rate).




Figure 5. Sensibilité de la précision au learning rate, par optimiseur.




Figure 6. Entraînement vs test : l'écart mesure le sur-apprentissage.

4.3 Analyse des résultats

Effet de l'architecture. Les performances progressent de CNN1 (LeNet-5) vers les VGG avec la profondeur : CNN1 64.3 % ; VGG1 68.6 % ; VGG2 74.3 % ; VGG3 75.5 % ; VGG3+D 78.6 % ; VGG3+D+BN 82.8 %. Empiler des blocs convolutifs accroît la capacité d'extraction de caractéristiques, donc la précision, jusqu'à un palier.

Effet de l'optimiseur. Le meilleur optimiseur dépend du learning rate. Au learning rate adapté (LR=0.001), Adam surpasse SGD (ex. VGG3 à LR=0.001 : Adam 75.5 % contre SGD 71.7 %). Mais à 0.01 et 0.1, Adam devient instable et diverge, alors que SGD reste robuste : 7 divergence(s) pour Adam contre 4 pour SGD. Gagnant par learning rate : LR=0.001 : Adam (74 %) ; LR=0.01 : SGD (72 %) ; LR=0.1 : SGD (28 %). Adam est le meilleur à faible LR, SGD plus sûr à LR élevé.

Effet du learning rate. Précision moyenne par LR : LR=0.001 → 72.0 % ; LR=0.01 → 57.4 % ; LR=0.1 → 23.0 % ; meilleur compromis LR=0.001. Un LR trop élevé fait diverger Adam (précision ~10 %, niveau du hasard) : son pas adaptatif sature la sortie softmax. SGD reste stable. La sensibilité au learning rate est une faiblesse d'Adam et une force de SGD.

Effet de la régularisation (VGG3, Adam, LR=0.001). En partant de VGG3 (75.5 % (écart train-test 11.7 pts)),

l'ajout du Dropout donne 78.6 % (ecart train-test 5.2 pts), puis l'ajout de la Batch Normalization donne 82.8 % (ecart train-test 6.2 pts). La regularisation reduit le surapprentissage ; la Batch Normalization stabilise en outre l'entrainement et autorise des learning rates plus eleves.

Batch Normalization et robustesse au learning rate. A LR=0.1, seul le modele avec Batch Normalization evite la divergence (jusqu'a 81.8 %), tandis que les autres s'effondrent au niveau du hasard (au mieux 44 %). C'est la demonstration du benefice central de la BN : en normalisant les activations, elle empeche l'explosion des gradients et autorise des learning rates bien plus eleves.

4.4 Courbes d'apprentissage (learning rate = 0.001)

Perte et precision (entrainement + test) pour chaque modele, sous SGD puis Adam.




Figure 7. CNN1 / SGD / LR=0.001.




Figure 8. CNN1 / Adam / LR=0.001.




Figure 9. VGG1 / SGD / LR=0.001.




Figure 10. VGG1 / Adam / LR=0.001.




Figure 11. VGG2 / SGD / LR=0.001.




Figure 12. VGG2 / Adam / LR=0.001.




Figure 13. VGG3 / SGD / LR=0.001.




Figure 14. VGG3 / Adam / LR=0.001.




Figure 15. VGG3+D / SGD / LR=0.001.




Figure 16. VGG3+D / Adam / LR=0.001.




Figure 17. VGG3+D+BN / SGD / LR=0.001.




Figure 18. VGG3+D+BN / Adam / LR=0.001.

5. Modèle retenu

Conformément à l'énoncé, le modèle retenu est la meilleure configuration : VGG3+D+BN / Adam / LR=0.001, reentraîne plus longtemps (n'utilise que les architectures imposées).

Indicateur	Valeur
Architecture	VGG3+D+BN
Optimiseur / LR	Adam / 0.001
Précision de test	84.81 %
Perte de test	0.460
Paramètres	115 370
Époques	88 / 100

Table 5. Modèle retenu.

A noter : même reentraîne longtemps (jusqu'à 100 époques), ce modèle plafonne autour de 84-85 %. Ce n'est pas un défaut d'entraînement mais une limite de CAPACITÉ : l'architecture imposée est volontairement petite (blocs VGG à 32 filtres seulement, ~114 000 paramètres). La précision d'entraînement et la précision de test restent proches (autour de 85 %), ce qui indique une sous-capacité et non du surapprentissage : le réseau atteint sa limite de représentation. Au-delà, ce n'est plus le nombre d'époques qui compte mais la capacité du modèle -- d'où les extensions des sections 6 et 7 (architecture plus large : 89.6 % ; transfer learning : 97.9 %).




Figure. Courbes du modèle retenu.




Figure. Matrice de confusion du modèle retenu (%).




Figure. Précision par classe du modèle retenu.

Classe la mieux reconnue : grenouille (93.3 %) ; la plus difficile : chat (65.7 %). Confusions entre classes proches.

6. Bonus 1 : transfer learning (modele plus léger)

Première extension (hors énoncé) par transfer learning : un réseau EfficientNetB0 (transfer learning) pré-entraîné sur ImageNet, dont les images CIFAR-10 sont agrandies puis le réseau affine. Backbone plus léger (entraînement rapide), déjà très performant grâce au transfert de connaissances.

Indicateur	Valeur
Modele	EfficientNetB0 (transfer learning)
Precision de test	96.64 %
Perte de test	0.099
Parametres	4 062 381
Epoques	25 / 25

Table 6. Modele transfer learning (leger).

Ce modele atteint 96.64 %, au-delà des architectures imposees.




Figure. Courbes (Modele transfer (leger)).




Figure. Matrice de confusion (Modele transfer (leger), %).




Figure. Precision par classe (Modele transfer (leger)).




Figure. Exemples mal classés (V = réel, P = prédit).

7. Bonus 2 : transfer learning (precision maximale)

Seconde extension visant la precision maximale : le transfer learning. Un reseau EfficientNetB5_TL pre-entraine sur ImageNet est reutilise ; les images CIFAR-10 (32x32) sont agrandies a 456x456, puis le reseau est affine en deux phases (tete de classification, puis fine-tuning complet a faible learning rate, en mixed precision pour exploiter le GPU). Le transfert de connaissances depuis ImageNet permet d'atteindre une precision nettement superieure aux modeles entraines de zero.

Indicateur	Valeur
Modele	EfficientNetB5_TL
Resolution d'entree	456 x 456
Precision de test	97.91 %
Perte de test	0.071
Parametres	28 534 017
Epoques (fine-tuning)	15 / 15

Table 7. Transfer learning (precision maximale).

Ce modele atteint 97.91 % de precision — le meilleur resultat du projet.




Figure. Courbes du modele transfer learning.




Figure. Matrice de confusion (transfer learning, %).




Figure. Precision par classe (transfer learning).




Figure. Exemples mal classés (transfer learning).

8. Application interactive : test sur images inédites (CINIC-10)

Phase de déploiement de la méthodologie CRISP-DM : un petit jeu interactif met le modèle à l'épreuve. Tester le modèle sur le jeu de test CIFAR-10 s'est révélé peu instructif et peu ludique -- le modèle reconnaît presque tout sans difficulté. Pour une démonstration plus réaliste, le jeu utilise donc CINIC-10 : des images réelles dérivées d'ImageNet, redimensionnées en 32x32 et JAMAIS vues lors de l'entraînement.

Ces images, fortement compressées au format 32x32, perdent en qualité, ce qui rend la reconnaissance nettement plus difficile (données hors distribution). Le modèle s'en sort néanmoins bien lors des tests manuels, ce qui démontre une réelle capacité de généralisation au-delà du jeu d'entraînement. L'utilisateur teste les images une à une (trois propositions, un bouton par image) et un score est tenu à jour en direct.

Préparation du dataset CINIC-10 (images ImageNet redimensionnées en 32x32, JAMAIS vues par le modèle)...
 🗨️ Extraction à la volée de quelques images inédites depuis l'archive...
 🗨️ 300 images CINIC-10 prêtes pour le jeu !
 ✅ Modèle utilisé pour le jeu : VGG3_drop_bn




Figure. Jeu interactif : le modèle teste sur des images CINIC-10 inédites (issues d'ImageNet).

9. Conclusion generale

Ce projet a deroule une demarche complete de classification d'images (CRISP-DM). Le pretraitement (normalisation, one-hot) est indispensable a un entrainement stable. Les VGG dépassent largement CNN1 (LeNet-5), la profondeur ameliorant l'extraction de caracteristiques.

Adam est le plus efficace a faible learning rate mais sensible (il diverge a 0.01 et 0.1) ; SGD est plus lent mais robuste. Une valeur faible (0.001) est le meilleur compromis. Dropout et Batch Normalization limitent le surapprentissage ; la BN autorise en plus des learning rates eleves.

Le modele retenu (VGG3+D+BN / Adam / LR=0.001) atteint 84.81 % sur le test.

En complement (hors enonce), un modele optimise entraine de zero (augmentation + filtres croissants) atteint 96.64 %.

Enfin, le transfer learning (EfficientNetB5_TL pre-entraine sur ImageNet, affine) porte la precision a 97.91 % — le meilleur resultat du projet, illustrant la puissance du transfert de connaissances par rapport a un entrainement de zero.

Pistes : architectures residuelles (ResNet), recherche systematique des hyperparametres, augmentation avancee (MixUp, RandAugment).

10. References

- Simonyan, K. & Zisserman, A. (2014). Very Deep Convolutional Networks for Large-Scale Image Recognition (VGG). arXiv:1409.1556.
- Kingma, D. P. & Ba, J. (2015). Adam: A Method for Stochastic Optimization. ICLR.
- Srivastava, N. et al. (2014). Dropout: A Simple Way to Prevent Neural Networks from Overfitting. JMLR 15.
- Ioffe, S. & Szegedy, C. (2015). Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift. ICML.
- Tan, M. & Le, Q. (2019). EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks. ICML.
- Krizhevsky, A. (2009). Learning Multiple Layers of Features from Tiny Images (CIFAR-10).
- LeCun, Y. et al. (1998). Gradient-Based Learning Applied to Document Recognition (LeNet-5).
- Analytics Vidhya (2021). A Comprehensive Guide on Deep Learning Optimizers.